

**ΟΙΚΟΝΟΜΙΚΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΑΘΗΝΩΝ**



**ATHENS UNIVERSITY
OF ECONOMICS
AND BUSINESS**

Τμήμα Στατιστικής

Ανάλυση Δεδομένων

ΕΡΓΑΣΙΑ 8

Μελέτη Καρδιοπάθειας Framingham

Ναούμ Απόστολος

s6230068

Απρίλιος 2026

Περιεχόμενα

1	Εισαγωγή – Περιγραφή μελέτης και προβλήματος	2
2	Περιγραφική Ανάλυση	3
3	Σχέσεις μεταβλητών ανά 2	4
3.1	Παράγοντες που επηρεάζουν τον Καρδιακό Ρυθμό	4
3.2	Παράγοντες που σχετίζονται με το Σωματικό Βάρος	5
3.3	Συσχετίσεις μεταξύ Ποιοτικών Μεταβλητών	6
3.4	Παράγοντες που σχετίζονται με την Ηλικία	7
4	Προβλεπτικά &Ερμηνευτικά Μοντέλα	7
4.1	Εύρεση Βέλτιστου Μοντέλου	7
4.2	Εκτίμηση Μοντέλου	8
4.3	Ερμηνεία των Παραμέτρων	8
4.4	Έλεγχοι Προϋποθέσεων	9
5	Συμπεράσματα και Συζήτηση	10
	Αναφορές	11
	Παράρτημα	12

1 Εισαγωγή – Περιγραφή μελέτης και προβλήματος

Οι καρδιαγγειακές παθήσεις αποτελούν την κύρια αιτία αναπηρίας και θανάτου παγκοσμίως, με τον αριθμό των θανάτων να ξεπερνά τα 20 εκατομμύρια κάθε χρόνο. Συνεπώς, για την αντιμετώπιση αυτών των παθήσεων είναι απαραίτητη η γνώση και η κατανόηση των παραγόντων που επηρεάζουν σημαντικά τη λειτουργία της καρδιάς. Η συγκεκριμένη ανάλυση βασίζεται στη «Μελέτη Καρδιοπάθειας του Framingham», μια μεγάλη και ιστορική έρευνα που πραγματοποιήθηκε στις ΗΠΑ σε καρδιοπαθείς, ξεκινώντας από το 1948, με τη βάση δεδομένων να ανανεώνεται συνεχώς μέχρι και σήμερα.

Ο κύριος στόχος αυτής της μελέτης είναι η διερεύνηση των παραγόντων που σχετίζονται με τον καρδιακό ρυθμό, μια μέτρηση που συνδέεται άμεσα με την καρδιαγγειακή υγεία του ανθρώπου. Η ανάλυση έχει γίνει σε ένα δείγμα 134 ασθενών με προϋπάρχοντα καρδιακά προβλήματα και περιλαμβάνει δεδομένα από τις εξής 13 μεταβλητές:

- **Heartrate:** Καρδιακός ρυθμός (σε χτύπους ανά λεπτό).
- **Weight:** Βάρος (σε pounds)
- **Height:** Ύψος (σε ίντσες).
- **Age:** Ηλικία του ασθενούς.
- **Gender:** 1=Άνδρας, 2=Γυναίκα
- **White:** Φυλή (1=Λευκή, 0=Μη-λευκή).
- **MI:** Ιστορικό εμφράγματος του μυοκαρδίου (1=Ναι, 0=Όχι).
- **Typediabetes:** Είδος διαβήτη (0=Δεν πάσχει από διαβήτη, 1=Πάσχει από διαβήτη Τύπου 1, 2=Πάσχει από διαβήτη Τύπου 2).
- **Asthma:** Αν ο ασθενής πάσχει από άσθμα (1=Ναι, 0=Όχι).
- **Famhyper:** Αν ο ασθενής παρουσιάζει οικογενειακό ιστορικό υψηλής πίεσης (1=Ναι, 0=Όχι).
- **Smoker:** Ιστορικό καπνίσματος στο παρελθόν (1=Ναι, 0=Όχι).
- **Oralhypoglcemic:** Χρήση υπογλυκαιμικών χαπιών (για το διαβήτη): (1=Ναι, 0=Όχι).

Με την ανάλυση των διαθέσιμων δεδομένων, η μελέτη δίνει απαντήσεις σε κρίσιμα ερευνητικά ερωτήματα, όπως αν ο καρδιακός ρυθμός εξαρτάται από την ηλικία ή το είδος του διαβήτη που πάσχει ο ασθενής και κατά πόσο σχετίζεται το βάρος και ο καρδιακός ρυθμός του με το ιστορικό καπνίσματος και το ιστορικό εμφράγματος του μυοκαρδίου του.

Για την απάντηση των ερωτημάτων και την εξαγωγή συμπερασμάτων, οργανώσαμε τη συνέχεια της αναφοράς σε τέσσερις ενότητες. Αρχικά, κάνουμε μία παρουσίαση και περιγραφή των δεδομένων για μία γρήγορη κατανόηση της δομής και της κατανομής τους (Ενότητα 2). Στη συνέχεια, γίνεται έλεγχος για τις ανά δύο εξαρτήσεις των μεταβλητών που θεωρήθηκε λογικό να εξεταστούν (Ενότητα 3), ενώ ακολουθεί η προσαρμογή του γραμμικού υποδείγματος που εκτιμήσαμε για την εξέταση της σχέσης του καρδιακού ρυθμού με τις υπόλοιπες μεταβλητές (Ενότητα 4). Η μελέτη μας ολοκληρώνεται με τα συμπεράσματα και την συζήτηση των αποτελεσμάτων στα οποία οδήγησε η έρευνα (Ενότητα 5).

2 Περιγραφική Ανάλυση

Ποσοτικά Χαρακτηριστικά του Δείγματος:

Για την καλύτερη κατανόηση των δεδομένων του δείγματος υπολογίσαμε τα βασικά περιγραφικά μέτρα των ποσοτικών μεταβλητών, τα οποία συνοψίζονται στον **Πίνακα 1**.


Το δείγμα αποτελείται από καρδιοπαθείς μέσης και τρίτης ηλικίας με μέσο όρο τα 64.8 έτη και τυπική απόκλιση 9.2. Ο μέσος καρδιακός ρυθμός του δείγματος είναι 67.67 χτύποι ανά λεπτό, με το 74% των παρατηρήσεων να βρίσκεται στο διάστημα [55, 85], μετρήσεις που θεωρούνται φυσιολογικές για έναν υγιή ενήλικα και υποδηλώνουν καλή λειτουργία της καρδιάς (Harvard Health, 2021). Ωστόσο λόγω της μεγάλης απόκλισης μεταξύ της ελάχιστης και μέγιστης τιμής του καρδιακού ρυθμού, διαπιστώσαμε ότι υπάρχει μεγάλη ετερογένεια μεταξύ των ασθενών, το οποίο είναι αρκετά χρήσιμο για την ανάλυση και την εύρεση των παραγόντων που την προκαλούν. Το σωματικό βάρος εμφανίζει μεγάλη μεταβλητότητα, κάτι που διευκολύνει την διερεύνηση της συσχέτισής του με την καρδιακή λειτουργία, σε αντίθεση με το ύψος στο οποίο παρουσιάζεται σχετικά μικρή διασπορά στους ασθενείς.

Πίνακας 1: Περιγραφικά Μέτρα Ποσοτικών Μεταβλητών

Μεταβλητή	Μέσος	Τυπ. Απόκλ.	Διάμεσος	Ελάχ.	Μέγ.	Ασυμμετρία	Κύρτωση
Ηλικία (Age)	64.84	9.19	65.0	39	84	-0.09	-0.59
Καρδιακός Ρυθμός (HeartRate)	67.67	12.74	67.0	46	105	0.61	-0.09
Βάρος (Weight)	194.13	33.54	190.1	131	307	0.90	1.23
Ύψος (Height)	68.69	3.16	68.9	60	77	-0.28	0.11

Κατανομή των Δεδομένων:

Όπως απεικονίζεται στα διαγράμματα του παραρτήματος, οι ηλικίες (βλ. Διαγράμματα A1,A2) και τα ύψη των ασθενών (βλ. Διαγράμματα A3,A4) παρουσιάζουν μία ισορροπημένη και συμμετρική κατανομή, χωρίς την παρουσία ακραίων τιμών. Η παρουσία ακραίων τιμών στο σωματικό βάρος των ασθενών (π.χ. περιπτώσεις παχυσαρκίας) επηρεάζει την κατανομή των δεδομένων, προκαλώντας την ασυμμετρία της μεταβλητής του βάρους (βλ. Διαγράμματα A5, A6). Για τον ίδιο λόγο παρατηρούμε ότι και η κατανομή του καρδιακού ρυθμού παρουσιάζει δεξιά ασυμμετρία (βλ. Διάγραμμα 1).



Σχήμα 1: Ιστόγραμμα του Καρδιακού Ρυθμού

Ποιοτικά Χαρακτηριστικά του Δείγματος:

Όσον αφορά τα ποιοτικά χαρακτηριστικά, η πλειοψηφία των ασθενών του δείγματος είναι άνδρες (85.1%) και άτομα λευκής φυλής (88.8%). Επιπλέον, για τις συνήθειες και τον τρόπο ζωής τους παρατηρείται ότι αρκετοί ασθενείς (61.2%) έχουν ιστορικό καπνίσματος, ενώ σχεδόν οι μισοί (44%) λαμβάνουν συμπληρώματα πολυβιταμινών.

Σχετικά με το ιατρικό τους προφίλ, ενδιαφέρον παρουσιάζει το γεγονός ότι περισσότεροι από τους μισούς (61.9%) έχουν οικογενειακό ιστορικό υψηλής πίεσης. Αντίθετα, το άσθμα εμφανίζεται σχετικά σπάνια, καθώς νοσεί μόλις το 7.5% του δείγματος. Επιπλέον, σχεδόν ένας στους τρεις ασθενείς (29.9%) έχει υποστεί έμφραγμα του μυοκαρδίου στο παρελθόν. Το 32.1% του δείγματος πάσχει από διαβήτη, από τους οποίους συχνότερος είναι ο διαβήτης Τύπου 2 (21.6%) σε σχέση με τον Τύπου 1 (10.4%). Τέλος, το 18.7% του συνολικού δείγματος κάνει χρήση υπογλυκαιμικών χαπιών για τη ρύθμιση του σακχάρου. Οι αναλυτικές συχνότητες για τα παραπάνω ποιοτικά χαρακτηριστικά του δείγματος συνοψίζονται στον αντίστοιχο πίνακα του Παραρτήματος (βλ. Πίνακας Α1)..

3 Σχέσεις μεταβλητών ανά 2

Σε αυτή την ενότητα θα εξετάσουμε αν τα χαρακτηριστικά των ασθενών σχετίζονται μεταξύ τους, προκειμένου να έχουμε μία πρώτη εικόνα για τις μεταβλητές που θα είναι χρήσιμες στην ανάλυση. Πριν την ανάλυση, σημειώνουμε ότι η μεταβλητή του καρδιακού ρυθμού δεν ακολουθεί την κανονική κατανομή (Shapiro-Wilk $p < 0.01$, Kolmogorov-Smirnov $p < 0.01$), για λεπτομέρειες βλ. Διαγράμματα Α7 και Α8 στο Παράρτημα.

3.1 Παράγοντες που επηρεάζουν τον Καρδιακό Ρυθμό

Καρδιακός Ρυθμός (HeartRate) ~ Ηλικία (Age)

Αρχικά, εξετάσαμε αν η ηλικία του ασθενούς σχετίζεται με τον καρδιακό του ρυθμό. Λόγω της μη κανονικότητας της μεταβλητής HeartRate, χρησιμοποιήσαμε τον έλεγχο γραμμικής συσχέτισης του Spearman, ο οποίος είναι ο πιο ανθεκτικός σε αποκλίσεις της κανονικότητας. Τα αποτελέσματα έδειξαν ότι υπάρχει μια στατιστικά σημαντική, αρνητική συσχέτιση (Spearman's $\rho = -0.24$, $p\text{-value} < 0.01$), γεγονός που υποδηλώνει ότι οι παλμοί τείνουν να μειώνονται ελαφρώς καθώς η ηλικία αυξάνεται (για λεπτομέρειες βλ. το αντίστοιχο διάγραμμα διασποράς, **Διάγραμμα 2**).

Καρδιακός Ρυθμός (HeartRate) ~ Είδος Διαβήτη (Typediabetes)

Όσον αφορά τα ιατρικά χαρακτηριστικά των ασθενών, εξετάσαμε την επίδραση του διαβήτη. Κατά τον έλεγχο των προϋποθέσεων για την Ανάλυση Διακύμανσης (ANOVA), ο έλεγχος Levene έδειξε ότι ισχύει η ομοσκεδαστικότητα μεταξύ των ομάδων ($p = 0.15$), ενώ η κανονικότητα των καταλοίπων απορρίφθηκε (SW $p < 0.01$). Επιπλέον, το μέγεθος του δείγματος για τους ασθενείς με διαβήτη Τύπου 1 ήταν μικρό ($n < 50$). Επομένως, επιλέξαμε τον πιο κατάλληλο μη παραμετρικό έλεγχο Kruskal-Wallis. Η ανάλυση έδειξε ότι δεν υπάρχει στατιστικά σημαντική διαφοροποίηση στον διάμεσο χτύπο ανά λεπτό μεταξύ των δύο τύπων διαβήτη ή της απουσίας αυτού ($p = 0.06$). Το σχετικό θηκόγραμμα παρουσιάζεται στο Παράρτημα (Διάγραμμα Α9).


Καρδιακός Ρυθμός (HeartRate) ~ Ιστορικό Καπνίσματος (Smoker)

Προκειμένου να διερευνήσουμε τη σχέση του καρδιακού ρυθμού με το ιστορικό καπνίσματος των ασθενών, χρησιμοποιήσαμε τον έλεγχο (t-test), καθώς παρά την απόρριψη της κανονικότητας του καρδιακού ρυθμού, το μεγάλο μέγεθος των ομάδων ($n > 50$ σε κάθε κατηγορία) μας επέτρεψε την εφαρμογή του λόγω του


Κεντρικού Οριακού Θεωρήματος. Επιπλέον, δεν απορρίφθηκε ο έλεγχος ισότητας των διακυμάνσεων (F-test $p=0.826$). Βάσει αυτού του αποτελέσματος, εκτελέσαμε τον έλεγχο ισότητας μέσω των τιμών, ο οποίος έδειξε ότι οι καπνιστές και οι μη καπνιστές έχουν πρακτικά ίδιους χτύπους ανά λεπτό (t-test $p=0.739$), για λεπτομέρειες βλ. Διάγραμμα A10 στο Παράρτημα.

Καρδιακός Ρυθμός (HeartRate) ~ Οικογενειακό Ιστορικό Υψηλής Πίεσης (Famhyper)

Αντίθετα, ενδιαφέρον παρουσιάζει η επίδραση της κληρονομικότητας της αρτηριακής πίεσης. Έχοντας εξασφαλίσει την ισότητα των διακυμάνσεων (F-test $p = 0.76$), διαπιστώσαμε μέσω του ελέγχου ότι οι ασθενείς με οικογενειακό ιστορικό υψηλής πίεσης εμφανίζουν στατιστικά σημαντικά υψηλότερο καρδιακό ρυθμό (69.9 χτύπους/λεπτό κατά μέσο όρο) από εκείνους που δεν έχουν αντίστοιχο ιστορικό (64.1 χτύπους/λεπτό) (t-test $p = 0.01$). Η διαφοροποίηση αυτή απεικονίζεται στο **Διάγραμμα 3**.



Σχήμα 2: Διάγραμμα Διασποράς: Καρδιακός Ρυθμός vs Ηλικία



Σχήμα 3: Error bar: Καρδιακός Ρυθμός vs Οικ. Ιστορικό Υψηλής Πίεσης

3.2 Παράγοντες που σχετίζονται με το Σωματικό Βάρος

Το σωματικό βάρος των ασθενών, που δεν ακολουθεί κανονική κατανομή βάσει των ελέγχων Shapiro-Wilk και Kolmogorov-Smirnov ($p < 0.05$) αποτέλεσε βασικό μέρος της διερεύνησής μας, καθώς αποτελεί σημαντικό παράγοντα κινδύνου για τις καρδιοπάθειες.

Σωματικό Βάρος (Weight) ~ Ιστορικό Καπνίσματος (Smoker)

Σε αυτό το σημείο της μελέτης μας ενδιαφέρει να διερευνήσουμε αν το μέσο βάρος των ασθενών διαφοροποιείται ανάλογα με το ιστορικό καπνίσματός τους. Ο έλεγχος των δεδομένων έδειξε ότι η κατανομή τους δεν είναι η κανονική (SW $p < 0.01$) για κάθε ομάδα. Επίσης, παρόλο που τα μεγέθη των ομάδων ήταν ικανοποιητικά, η κατανομή του βάρους παρουσίαζε ασυμμετρία και στις δύο ομάδες με αποτέλεσμα ο μέσος να μην είναι το κατάλληλο μέτρο περιγραφής των συγκεκριμένων δεδομένων (για τα αντίστοιχα Ιστογράμματα και Διαγράμματα Q-Q βλ. Παράρτημα, Διαγράμματα A11 έως A14). Γι' αυτόν τον λόγο εφαρμόσαμε τον μη παραμετρικό έλεγχο Wilcoxon Test, διαπιστώνοντας ότι οι καπνιστές και οι μη καπνιστές δεν διαφέρουν στατιστικά σημαντικά ως προς το βάρος τους ($p = 0.59$). Το αποτέλεσμα αυτό φαίνεται και στο σχετικό θηκόγραμμα του Παραρτήματος (βλ. Διάγραμμα A15)

Σωματικό Βάρος (Weight) ~ Είδος Διαβήτη (Typediabetes)

Για την ανάλυση της σχέσης του βάρους με τον διαβήτη, καθώς απορρίφθηκε ο έλεγχος κανονικότητας των καταλοίπων της Ανάλυσης Διακύμανσης (SW και KS $p < 0.01$), χρησιμοποιήσαμε τον μη παραμετρικό έλεγχο

Kruskal-Wallis. Τα αποτελέσματα έδειξαν ότι ο τύπος του διαβήτη δεν επηρεάζει σημαντικά το σωματικό βάρος των ασθενών του δείγματος ($p = 0.12$), για λεπτομέρειες βλ. Διάγραμμα A16 στο Παράρτημα.


Σωματικό Βάρος (Weight) ~ Χρήση υπογλυκαιμικών χαπιών (Oralhypoglcemic)

Προχωράμε με την εξέταση της σχέσης του σωματικού βάρους με τη χρήση υπογλυκαιμικών χαπιών για τον διαβήτη. Ελέγχοντας τα δεδομένα με τον έλεγχο Wilcoxon, βρήκαμε στατιστικά σημαντική διαφορά ($p = 0.02$) ανάμεσα στους ασθενείς που λαμβάνουν την αγωγή (διάμεσο βάρος 206 pounds) και σε όσους δεν τη λαμβάνουν (διάμεσο βάρος 190 pounds). Το αποτέλεσμα του ελέγχου υποδηλώνει μια σημαντική θετική συσχέτιση ανάμεσα στις δύο μεταβλητές, εννοώντας ότι η φαρμακευτική αγωγή για τον διαβήτη σχετίζεται με την αύξηση του σωματικού βάρους (λεπτομέρειες στο Διάγραμμα A17 του Παραρτήματος).

3.3 Συσχετίσεις μεταξύ Ποιοτικών Μεταβλητών

Στη συνέχεια της ανάλυσής μας, εξετάσαμε τις πιθανές εξαρτήσεις μεταξύ των κατηγορικών μεταβλητών του δείγματος. Για αυτόν τον λόγο, χρησιμοποιήσαμε τον έλεγχο ανεξαρτησίας χ^2 του Pearson (Chi-squared test), ενώ όταν οι τιμές στα κελιά του πίνακα αναμενόμενων τιμών χ^2 ήταν πολύ μικρές, εκτελέσαμε τον ακριβή έλεγχο του Fisher (Fisher's Exact Test).

Όπως ήταν αναμενόμενο, βρήκαμε ότι η χρήση υπογλυκαιμικών χαπιών για τον διαβήτη εξαρτάται σε μεγάλο βαθμό από το είδος του διαβήτη που πάσχει ο ασθενής (Fisher's $p < 0.01$), καθώς η αγωγή αυτή δεν χορηγείται σε ασθενείς που δεν πάσχουν από διαβήτη αλλά κυρίως σε ασθενείς με διαβήτη Τύπου 2 (για λεπτομέρειες βλ. Διάγραμμα A18 στο Παράρτημα). Ένα άλλο ενδιαφέρον αποτέλεσμα είναι το γεγονός ότι το οικογενειακό ιστορικό υψηλής πίεσης (famhyper) σχετίζεται στατιστικά σημαντικά τόσο με τη χρήση υπογλυκαιμικών χαπιών (Pearson $p < 0.01$, βλ. Διάγραμμα A19), όσο και με την εμφάνιση της νόσου του διαβήτη (Pearson $p < 0.01$). Αυτή η διαφοροποίηση απεικονίζεται στο **Διάγραμμα 4**, στο οποίο φαίνεται η σχετική συχνότητα εμφάνισης του τύπου διαβήτη ανάλογα με το οικογενειακό ιστορικό υψηλής πίεσης του ασθενή.



Σχήμα 4: Ραβδόγραμμα Συχνοτήτων: Είδος Διαβήτη vs Οικ. Ιστορικό Υψηλής Πίεσης

Αντιθέτως, το φύλο των ασθενών δεν βρέθηκε να σχετίζεται με το ιστορικό εμφράγματος του μυοκαρδίου (Pearson με διόρθωση συνέχειας Yates $p = 1.000$), ούτε με το είδος του διαβήτη (Fisher's $p = 0.404$). Επιπλέον,

η εκδήλωση εμφράγματος του μυοκαρδίου στο παρελθόν δεν παρουσίασε στατιστικά σημαντική εξάρτηση από το κάπνισμα (Pearson $p = 0.567$) ή από το οικογενειακό ιστορικό υψηλής πίεσης του ασθενή (Pearson $p = 0.634$). Το ιστορικό καπνίσματος δεν βρέθηκε να επηρεάζει σημαντικά τα ποσοστά εμφάνισης άσθματος του δείγματος (Fisher's $p = 0.315$). Για να επιβεβαιώσουμε οπτικά αυτές τις μη στατιστικά σημαντικές εξαρτήσεις, παρουσιάζουμε τα Διαγράμματα A20 - A24 στο Παράρτημα.

3.4 Παράγοντες που σχετίζονται με την Ηλικία

Σε αυτό το σημείο, ελέγξαμε αν η ηλικία ως ποσοτική μεταβλητή εξαρτάται από το είδος του διαβήτη ή από το ιστορικό εμφράγματος του μυοκαρδίου των ασθενών. Ακολουθήσαμε τη μέθοδο της Ανάλυσης Διακυμάνσεων, καθώς δεν μπορούσαμε να απορρίψουμε την υπόθεση ομοιογένειας των διακυμάνσεων των ομάδων (Levene $p = 0.63$), ούτε την υπόθεση κανονικότητας των καταλοίπων (SW $p = 0.43$). Τα αποτελέσματα δεν έδειξαν σημαντικές διαφορές στις ηλικίες των ασθενών μεταξύ των τύπων διαβήτη (ANOVA $p = 0.77$, βλ. Διάγραμμα A25 στο Παράρτημα). Αντίστοιχα, αν και οι ασθενείς με ιστορικό εμφράγματος ήταν κατά μέσο όρο λίγο νεότεροι (62.7 έναντι 65.7 ετών), η διαφορά αυτή δεν ήταν στατιστικά σημαντική σε επίπεδο σημαντικότητας 5% (t-test $p = 0.09$, βλ. Διάγραμμα A26 στο Παράρτημα).

4 Προβλεπτικά & Ερμηνευτικά Μοντέλα

Στην ενότητα αυτή, σκοπός μας είναι να εκτιμήσουμε ένα πολυδιάστατο γραμμικό μοντέλο (Multiple Linear Regression), το οποίο θα μπορεί να εξηγήσει και να εκτιμήσει τον καρδιακό ρυθμό (HeartRate) ενός καρδιοπαθή ανάλογα με τα χαρακτηριστικά και το ιατρικό ιστορικό του.

4.1 Εύρεση Βέλτιστου Μοντέλου

Για την κατασκευή του αρχικού μοντέλου υπολογίσαμε τους τετραγωνικούς όρους της ηλικίας (age^2) και του βάρους ($weight^2$), έτσι ώστε να ελέγξουμε πιθανές μη γραμμικές σχέσεις μεταξύ των μεταβλητών. Επομένως, ξεκινήσαμε με την εκτίμηση του πλήρους γραμμικού υποδείγματος, το οποίο περιελάμβανε όλες τις διαθέσιμες μεταβλητές του δείγματος, προσθέτοντας τις νέες μεταβλητές που κατασκευάσαμε, την (age^2) και την ($weight^2$).

Για να μειώσουμε το πρόβλημα της πολυσυγγραμμικότητας, το οποίο παρουσιάζεται συχνά σε μοντέλα με πολλές μεταβλητές, εξετάσαμε τους Συντελεστές Πληθωρισμού Διακυμάνσεων (Variance Inflation Factor - VIF) του αρχικού μοντέλου. Από τη στατιστική βιβλιογραφία (Kennedy, 1992) γνωρίζουμε ότι για τις ποσοτικές μεταβλητές, τιμές του $VIF > 10$ υποδηλώνουν ότι οι μεταβλητές είναι προβληματικές. Αντίστοιχα, για τις κατηγορικές μεταβλητές εξετάζουμε το GVIF (Generalized Variance Inflation Factor) και το συγκρίνουμε με το 3.16. Στο μοντέλο μας, οι μεταβλητές της ηλικίας και του βάρους παρουσίασαν $VIF > 150$ και > 80 αντίστοιχα. Το πρόβλημα αυτό είναι πιθανό να οφείλεται στο γεγονός ότι συμπεριλάβαμε ταυτόχρονα τους κανονικούς και τους τετραγωνικούς όρους. Αντί να αφαιρέσουμε τις μεταβλητές, επιλέξαμε να τις κεντράρουμε, αφαιρώντας τον μέσο όρο από κάθε παρατήρηση. Αυτό είχε ως αποτέλεσμα η πολυσυγγραμμικότητα να μειωθεί σημαντικά (όλα τα νέα $VIF < 3.5$).

Για την εύρεση του βέλτιστου μοντέλου εφαρμόσαμε την κλιμακωτή διαδικασία αφαίρεσης μεταβλητών (Backward procedure), ξεκινώντας από το αρχικό κεντραρισμένο μοντέλο με 14 παραμέτρους. Η μέθοδος αυτή χρησιμοποιεί ένα κριτήριο πληροφορίας που βασίζεται στη μέγιστη λογαριθμο-πιθανοφάνεια, το Akaike Information Criterion (AIC). Συγκεκριμένα, το αρχικό μοντέλο των 14 παραμέτρων παρουσίασε τιμή $AIC = 674.1$. Μέσω της διαδικασίας επιλογής, καταλήξαμε σε ένα πιο απλό τελικό μοντέλο το οποίο περιλαμβάνει μόνο 7 μεταβλητές, επιτυγχάνοντας σημαντική μείωση του κριτηρίου AIC στο 661.48. Στη στατιστική

βιβλιογραφία (Burnham & Anderson, 2002), μια μείωση του AIC μεγαλύτερη του 10 υποδηλώνει ότι το νέο υπόδειγμα έχει καλύτερες προβλεπτικές δυνατότητες.

Η βελτίωση αυτή επιβεβαιώνεται και από τον Προσαρμοσμένο Συντελεστή Προσδιορισμού (Adjusted R^2). Ενώ το απλό R^2 μειώθηκε λίγο όπως περιμέναμε (από 25.2% σε 23.3%) λόγω της αφαίρεσης μεταβλητών, το Adjusted R^2 αυξήθηκε από 15.7% στο αρχικό μοντέλο σε 19.1% στο τελικό. Αυτό αποδεικνύει ότι οι μεταβλητές που αφαιρέθηκαν δεν προσέφεραν σημαντικά στην εκτίμηση του καρδιακού ρυθμού, και το νέο υπόδειγμα είναι πιο αξιόπιστο.

4.2 Εκτίμηση Μοντέλου

Το τελικό μοντέλο εξηγεί το 23.3% της συνολικής μεταβλητότητας του καρδιακού ρυθμού ($R^2 = 0.233$, F-statistic p-value < 0.01). Στον **Πίνακα 2** παρουσιάζονται αναλυτικά οι συντελεστές του τελικού μοντέλου.

Πίνακας 2: Αποτελέσματα Πολλαπλής Γραμμικής Παλινδρόμησης

Μεταβλητή	Συντελεστής (β)	Τυπ. Σφάλμα	t-value	p-value
Σταθερά (Intercept)	64.03	1.814	35.29	< 0.001
Φύλο: Γυναίκα	7.918	2.901	2.73	0.007
Διαβήτης: Τύπου 1	6.818	3.329	2.05	0.043
Διαβήτης: Τύπου 2	2.034	2.603	0.78	0.436
Οικ. Ιστορικό: Ναι	4.138	2.186	1.89	0.061
Βάρος (κεντραρισμένο)	0.092	0.036	2.56	0.012
Βάρος στο τετράγωνο	-0.001	0.0005	-1.95	0.054
Ηλικία (κεντραρισμένη)	-0.288	0.112	-2.58	0.011

Η εξίσωση της πολλαπλής γραμμικής παλινδρόμησης που προέκυψε από την διαδικασία εύρεσης του βέλτιστου μοντέλου είναι η εξής:

$$\begin{aligned} \widehat{\text{HeartRate}} = & 64.03 + 7.92 \cdot (\text{Female}) + 6.82 \cdot (\text{Type 1}) + 2.03 \cdot (\text{Type 2}) \\ & + 4.14 \cdot (\text{Famhyper}) + 0.09 \cdot (\text{Weight}_c) \\ & - 0.001 \cdot (\text{Weight}_c^2) - 0.29 \cdot (\text{Age}_c) \end{aligned} \quad (1)$$

4.3 Ερμηνεία των Παραμέτρων

Η ερμηνεία του κάθε συντελεστή (β) εκφράζει τη μεταβολή του καρδιακού ρυθμού για κάθε μονάδα αλλαγής της αντίστοιχης μεταβλητής, διατηρώντας όλους τους άλλους παράγοντες σταθερούς:

- **Σταθερά** ($\beta_0 = 64.03$): Λόγω του κεντραρίσματος των μεταβλητών Weight και Age, αντιπροσωπεύει την αναμενόμενη τιμή του καρδιακού ρυθμού ενός άνδρα που δεν πάσχει από διαβήτη, δεν παρουσιάζει οικογενειακό ιστορικό υψηλής πίεσης και έχει ηλικία και βάρος ίσα με τον μέσο όρο του δείγματος (64.83 και 194.13 αντίστοιχα). Θα θεωρήσουμε τους ασθενείς με αυτά τα χαρακτηριστικά ως κατηγορία αναφοράς για να διευκολύνουμε την ερμηνεία των ακόλουθων συντελεστών.
- **Φύλο** ($\beta_1 = 7.92$): Αν διατηρήσουμε τα υπόλοιπα χαρακτηριστικά σταθερά, μια γυναίκα ασθενής αναμένεται να παρουσιάζει κατά μέσο όρο 7.92 καρδιακούς χτύπους ανά λεπτό περισσότερους από έναν άνδρα της κατηγορίας αναφοράς.

- **Διαβήτης Τύπου 1** ($\beta_2 = 6.82$): Αν διατηρήσουμε τα υπόλοιπα χαρακτηριστικά σταθερά, ένας καρδιοπαθής που πάσχει από διαβήτη Τύπου 1 αναμένεται να παρουσιάζει κατά μέσο όρο περίπου 7 παλμούς περισσότερους από έναν άνδρα της κατηγορίας αναφοράς. Η τιμή είναι στατιστικά σημαντική ($p = 0.04$), υποδεικνύοντας ότι ο διαβήτης Τύπου 1 επιβαρύνει την καρδιακή λειτουργία.
- **Διαβήτης Τύπου 2** ($\beta_3 = 2.03$): Η επίδραση του διαβήτη Τύπου 2 δεν είναι στατιστικά σημαντική σε αυτό το μοντέλο ($p = 0.43$).
- **Οικ. Ιστορικό** ($\beta_4 = 4.14$): Οι χτύποι αυξάνονται κατά 4 περίπου αν ο ασθενής παρουσιάζει οικογενειακό ιστορικό υψηλής πίεσης (Οριακά μη σημαντικό, $p = 0.06$).
- **Σωματικό Βάρος** ($\beta_5 = 0.09, \beta_6 = -0.001$): Η θετική και στατιστικά σημαντική παράμετρος δείχνει ότι η αύξηση του βάρους αυξάνει τους παλμούς. Όμως, λόγω της παρουσίας του αρνητικού τετραγωνικού όρου, διαπιστώνεται ότι σε ακραία επίπεδα παχυσαρκίας, ο ρυθμός αύξησης των παλμών μικραίνει, καθώς η καρδιά δεν μπορεί να υπερβαίνει συνεχώς τα βιολογικά της όρια.
- **Ηλικία** ($\beta_7 = -0.29$): Για κάθε ένα επιπλέον έτος ηλικίας, οι χτύποι μειώνονται κατά 0.29 ($p=0.011$).

4.4 Έλεγχοι Προϋποθέσεων

Για την εκτίμηση του πολυδιάστατου γραμμικού μοντέλου, βασιστήκαμε σε τρεις βασικές υποθέσεις, την ομοσκεδαστικότητα, την κανονικότητα και την ανεξαρτησία των σφαλμάτων. Έτσι, προκειμένου να εξασφαλίσουμε την αξιοπιστία των εκτιμήσεών μας, κάναμε τους απαραίτητους διαγνωστικούς ελέγχους στα κατάλοιπα του τελικού γραμμικού μοντέλου. Συγκεκριμένα, εξετάστηκαν οι κλασικές υποθέσεις της Γραμμικής Παλινδρόμησης:


Ομοσκεδαστικότητα - Ακραίες Τιμές: Για τον έλεγχο της ομοσκεδαστικότητας των σφαλμάτων, διαχωρίσαμε τα δεδομένα σε τέσσερα διαστήματα και εφαρμόσαμε τον έλεγχο Levene στα τυποποιημένα κατάλοιπα (standardized residuals). Παίρνοντας $p = 0.611$, δεν απορρίπτεται η μηδενική υπόθεση της ισότητας των διακυμάνσεων. Το αποτέλεσμα αυτό επιβεβαιώνεται και από το διάγραμμα των προσαρμοσμένων τιμών (fitted values) έναντι των τυποποιημένων καταλοίπων, όπου τα σημεία φαίνεται ότι κατανέμονται τυχαία γύρω από το μηδέν (βλ. Διάγραμμα A27 στο Παράρτημα). Επιπλέον, παρατηρώντας και το διάγραμμα των τετραγωνικών τυποποιημένων καταλοίπων (Quadratic Standardized Residuals) έναντι των προσαρμοσμένων τιμών, διαπιστώνουμε ότι δεν υπάρχουν πολλές ακραίες τιμές που επηρεάζουν τα αποτελέσματα των εκτιμήσεων (βλ. Διάγραμμα A28 στο Παράρτημα). Το ίδιο συμπέρασμα επιβεβαιώνεται και από τα διαγράμματα Cook's Distance (βλ. Διαγράμματα A29, A30).

Κανονικότητα: Εκτελέσαμε τον έλεγχο κανονικότητας Shapiro-Wilk, απορρίπτοντας τη μηδενική υπόθεση σε επίπεδο σημαντικότητας 5% ($p = 0.021$). Ωστόσο, καθώς η απόρριψη ήταν οριακή και το μέγεθος του δείγματος είναι ικανοποιητικό ($n = 134$), θεωρήσαμε προτιμότερο να συμβουλευτούμε και τον έλεγχο Kolmogorov-Smirnov. Εφόσον ο συγκεκριμένος έλεγχος δεν απέρριψε την κανονικότητα ($p = 0.158$), η λύση πλέον είναι να κοιτάζουμε το γράφημα Q-Q plot (βλ. Διάγραμμα 5). Παρατηρούμε ότι τα κατάλοιπα προσεγγίζουν ικανοποιητικά την ευθεία κανονικότητας με μικρές αποκλίσεις στις ουρές της κατανομής, γεγονός που υποδεικνύει ότι δεν παραβιάζεται η αρχική προϋπόθεση.


Τυχαιότητα: Εξετάσαμε την υπόθεση της τυχαιότητας και της ανεξαρτησίας των σφαλμάτων μέσω του διαγράμματος Αυτοσυσχέτισης (βλ. Διάγραμμα 6) και του διαγράμματος των καταλοίπων ως προς τη σειρά παρατήρησης (Residuals vs Observation Order, βλ. Διάγραμμα A31 στο Παράρτημα). Κανένα από τα δύο γραφήματα δεν ανέδειξε κάποιο μοτίβο ή στατιστικά σημαντική αυτοσυσχέτιση (autocorrelation), ικανοποιώντας τη συγκεκριμένη προϋπόθεση. Το αποτέλεσμα αυτό επιβεβαιώθηκε με τη βοήθεια του

ελέγχου Durbin-Watson, για τον οποίο το στατιστικό κριτήριο D-W υπολογίστηκε 1.70 (αποδεκτή τιμή) και το $p\text{-value} = 0.05$.

Επομένως, οι διαγνωστικοί έλεγχοι που πραγματοποιήσαμε δείχνουν ότι το τελικό μοντέλο των 7 μεταβλητών ικανοποιεί τις προϋποθέσεις της Πολλαπλής Γραμμικής Παλινδρόμησης, καθιστώντας τα συμπεράσματά μας στατιστικά έγκυρα.



Σχήμα 5: Normal Q-Q Plot Μοντέλου



Σχήμα 6: Διάγραμμα Αυτοσυσχέτισης (ACF) Καταλοίπων

5 Συμπεράσματα και Συζήτηση

Με αυτή τη μελέτη είχαμε ως κύριο στόχο να διερευνήσουμε τους παράγοντες που επηρεάζουν τον καρδιακό ρυθμό των ασθενών με καρδιακά προβλήματα. Μέσα από τη στατιστική μας ανάλυση, κατασκευάσαμε ένα τελικό προβλεπτικό μοντέλο επτά μεταβλητών, από το οποίο βγάλαμε πολλά σημαντικά συμπεράσματα. Κάποια από αυτά συνοψίζονται παρακάτω.

Είδαμε ότι χαρακτηριστικά όπως το φύλο και η ηλικία ενός ανθρώπου παίζουν μεγάλο ρόλο. Συγκεκριμένα, οι γυναίκες στο δείγμα μας φάνηκε να έχουν κατά μέσο όρο σημαντικά περισσότερους παλμούς από τους άνδρες. Όσον αφορά στο θέμα της ηλικίας, βγάλαμε το λογικό συμπέρασμα, ότι όσο ο ασθενής μεγαλώνει μειώνεται ο καρδιακός του ρυθμός. Αντίθετα με την ηλικία, υπάρχει θετική συσχέτιση του σωματικού βάρους με τους καρδιακούς χτύπους ανά λεπτό, αφού όπως ήταν αναμενόμενο όταν το βάρος αυξάνεται η καρδιά ζορίζεται περισσότερο και αυξάνονται οι παλμοί. Σχετικά με το ιατρικό ιστορικό, ο Διαβήτης Τύπου 1 βρέθηκε να επιβαρύνει τη λειτουργία της καρδιάς ανεβάζοντας αισθητά τους παλμούς, σε αντίθεση με τον Διαβήτη Τύπου 2 όπου δεν φάνηκε να έχει σημαντική επίδραση. Παρόμοια συμπεριφορά είδαμε και στους ασθενείς που έχουν οικογενειακό ιστορικό υψηλής πίεσης, οι οποίοι εμφανίζουν υψηλότερο καρδιακό ρυθμό από εκείνους που δεν έχουν.

Συμπερασματικά, η ανάλυσή μας επιβεβαιώνει ότι οι καρδιακοί παλμοί καθορίζονται από έναν συνδυασμό χαρακτηριστικών, όπως το φύλο, την ηλικία, το σωματικό βάρος και το ιατρικό ιστορικό του κάθε ασθενούς.


Αναφορές

- [1] Harvard Health Publishing. (2021). *What your heart rate is telling you*. Harvard Medical School.
- [2] Kennedy, P. (1992). *A Guide to Econometrics*. MIT Press.
- [3] Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach*. Springer.


Παράρτημα

Πίνακας A1: Συχνότητες Ποιοτικών Χαρακτηριστικών του Δείγματος


Χαρακτηριστικό	Κατηγορία	Ποσοστό (%)
Φύλο (Gender)	Άνδρες / Γυναίκες	85.1% / 14.9%
Φυλή (White)	Λευκή / Μη-Λευκή	88.8% / 11.2%
Κάπνισμα (Smoker)	Ναι / Όχι	61.2% / 38.8%
Πολυβιταμίνες (VitMulti)	Ναι / Όχι	44.0% / 56.0%
Οικ. Ιστορικό (Famhyper)	Ναι / Όχι	61.9% / 38.1%
Έμφραγμα (MI)	Ναι / Όχι	29.9% / 70.1%
Άσθμα (Asthma)	Ναι / Όχι	7.5% / 92.5%
Διαβήτης (Typediabetes)	Όχι / Τύπου 1 / Τύπου 2	67.9% / 10.4% / 21.6%
Υπογλυκαιμικά (Oralhypoglceemic)	Ναι / Όχι	18.7% / 81.3%




Διάγραμμα A1: Ιστόγραμμα Ηλικίας




Διάγραμμα A2: Θηκόγραμμα (Boxplot) Ηλικίας




Διάγραμμα A3: Ιστόγραμμα Υψους




Διάγραμμα A4: Θηκόγραμμα (Boxplot) Υψους




Διάγραμμα A5: Ιστόγραμμα Βάρους




Διάγραμμα A6: Θηκόγραμμα (Boxplot) Βάρους




Διάγραμμα A7: Q-Q Plot Καρδιακού Ρυθμού




Διάγραμμα A8: Θηκόγραμμα (Boxplot) Καρδιακού Ρυθμού




Διάγραμμα A9: Θηκόγραμμα (Boxplot): Καρδ. Ρυθμός vs Διαβήτης




Διάγραμμα A10:Error bar: Καρδ. Ρυθμός vs Κάπνισμα




Διάγραμμα A11: Ιστόγραμμα Βάρους (Μη-Καπνιστές)




Διάγραμμα A12: Ιστόγραμμα Βάρους (Καπνιστές)




Διάγραμμα A13: Q-Q Plot Βάρους (Μη-Καπνιστές)




Διάγραμμα A14: Q-Q Plot Βάρους (Καπνιστές)




Διάγραμμα A15: Θηκόγραμμα (Boxplot): Βάρος vs Κάπνισμα




Διάγραμμα A16: Θηκόγραμμα (Boxplot): Βάρος vs Διαβήτης




Διάγραμμα A17: Θηκόγραμμα (Boxplot): Βάρος vs Υπογλυκαιμικά




Διάγραμμα A18: Ραβδόγραμμα (Barplot): Υπογλυκαιμικά vs Διαβήτης




Διάγραμμα A19: Ραβδόγραμμα (Barplot): Οικ. Ιστορικό Υψηλής Πίεσης vs Υπογλυκαιμικά




Διάγραμμα A20: Ραβδόγραμμα (Barplot): Φύλο vs Ιστ. Εμφράγματος




Διάγραμμα A21: Ραβδόγραμμα (Barplot): Φύλο vs Διαβήτης




Διάγραμμα A22: Ραβδόγραμμα (Barplot): Ιστ. Εμφράγματος vs Κάπνισμα




Διάγραμμα A23: Ραβδόγραμμα (Barplot): Ιστ. Εμφράγματος vs Οικ. Ιστορικό Υψηλής Πίεσης




Διάγραμμα A24: Ραβδόγραμμα (Barplot): Άσθμα vs Κάπνισμα




Διάγραμμα A25: Θηκόγραμμα (Boxplot): Ηλικία vs Διαβήτης




Διάγραμμα A26: Θηκόγραμμα (Boxplot): Ηλικία vs Ιστ. Εμφράγματος




Διάγραμμα A27: Διάγ. Διασποράς: Fitted Values vs Residuals




Διάγραμμα A28: Διάγ. Διασποράς: Fitted vs Quad. Standardized Residuals



Διάγραμμα A29: Διάγραμμα Cook's Distance



Διάγραμμα A30: Διάγραμμα Cook's Distance (Standardized Residuals vs Leverages)



Διάγραμμα A31: Διάγραμμα Διασποράς: Κατάλοιπα vs Σειρά Παρατήρησης